

Машинное обучение

Лекция 11

Кластеризация.
Отбор признаков.

Сергей Корпачев

НИУ ВШЭ, 2026

На прошлых лекциях

- Дано: матрица «объекты-признаки» X и, возможно, ответы y
- Найти: подмножество признаков или новые признаки

На прошлых лекциях

- Методы обучения с учителем: линейные модели, решающие деревья, случайные леса, ...
- Дано: матрица «объекты-признаки» X и ответы y
- Найти: модель $a(x)$


Обучение с учителем (supervised learning)

- Для каждого объекта известен ответ (класс или число)
- Даны примеры объектов с ответами
- Нужно построить модель, которая будет предсказывать ответы для новых объектов

Обучение без учителя (unsupervised learning)

- Даны объекты
- Нужно найти в них внутреннюю структуру
- Примеры:
 - Кластеризация
 - Обнаружение аномалий
 - Тематическое моделирование
 - Визуализация
 - Предсказание следующего кадра видео
 - ...
- Ближе к обучению в реальной жизни

Обучение без учителя: предсказание кадра



Обучение без учителя: кластеризация

Case 2. Оптимизация воронки продаж



ШАГ I

Анализ данных,
в т.ч. транзакционных
Way4, ЦОД, кред. фабрика

ШАГ II

Выявление паттернов и
сегментация клиентов
по характеристикам

ШАГ III

Формирование
продуктовых
предложений на базе
характеристик клиента




ЭКОНОМИЧЕСКИЙ ЭФФЕКТ

- ✓ Рост эффективности воронки продаж
- ✓ Рост лояльности клиентов

МЕТОДЫ алгоритмы кластеризации, визуализация данных большой размерности с использованием LargeVis

КЛАСТЕРИЗАЦИЯ КЛИЕНТОВ ПО ХАРАКТЕРУ ТРАНЗАКЦИЙ



В ЗАВИСИМОСТИ ОТ КЛАСТЕРА
КЛИЕНТА ПРЕДЛОЖИТЬ
РЕЛЕВАНТНЫЙ ПРОДУКТ



Паттерн	Продукт
1. Частая конвертация валют	Мультивалютный счет
2. Частые перелеты Аэрофлотом	Карта «Аэрофлот Бонус»
3. Частые поездки за границу	Страховка для выезжающих за рубеж
4. Переводы в благотворительные фонды	Карта «Подари жизнь»

Кластеризация

- Дано: матрица «объекты-признаки» X
- Найти:
 1. Множество кластеров Y
 2. Алгоритм кластеризации $a(x)$, который приписывает каждый объект к одному из кластеров
- Каждый кластер состоит из похожих объектов
- Объекты из разных кластеров существенно отличаются

Отличия

Обучение с учителем

- Цель: минимизация функционала ошибки
- Множество ответов известно заранее
- Конкретные способы измерения качества

Кластеризация

- Нет строгой постановки
- Множество кластеров неизвестно
- Правильные ответы отсутствуют (в большинстве случаев) — нельзя измерить качество

Зачем кластеризовать?



- Маркетинг: искать похожих клиентов
 - Модерация: проверять только одно сообщение из кластера
 - Соц. опросы: выделять группы схожих анкет
 - Соц. сети: искать сообщества
-
- Выявлять типы людей и формировать поведенческие паттерны для каждого типа

Важно

- Алгоритм кластеризации не знает, чего вы хотите
- Не стоит ожидать, что при кластеризации текстов вы получите разбиение именно по темам
- Нередко кластеры оказываются неинтерпретируемыми

Виды кластеризации


Форма кластеров




Форма кластеров




Различия в результатах работы



Исходная выборка
("Mouse" dataset)



Метод 1




Метод 2

Иерархическая кластеризация

Пример:

Кластеризация статей с Хабра



IT

Алгоритмы

Алгоритмы
и структуры
данных

Методы
машинного
обучения

Требования к кластерам

- Задача кластеризации новостей по содержанию.
- Постановка 1: в один кластер должны попадать новости на одну тему



Батыршин сыграет вместо Хабарова у «Магнитки» в матче с «Салаватом»

Место в третьей паре защиты «Магнитки» на третью встречу плей-офф Кубка Гагарина с «Салаватом Юлаевым» занял защитник Рафаэль Батыршин, сообщает из Уфы корреспондент «Чемпионата» Павел Панышев. Травмированный Ярослав Хабаров выбыл на неопределённый срок. Для форварда Оскара Осалы сезон закончен.



Футболисты ЦСКА проиграли «Долгопрудному» в товарищеском матче

Футболисты московского ЦСКА со счетом 2:3 проиграли клубу второго дивизиона "Долгопрудный" в товарищеском матче, который состоялся в Москве на стадионе "Октябрь". У армейцев забитыми мячами отличились Александр Цауня (15-я минута) и Сергей Ткачев (54).

Требования к кластерам

- Задача кластеризации новостей по содержанию.
- Постановка 2: в один кластер должны попадать новости об одном «большом» событии



Керлингистки сборной РФ сделали правильные выводы после ОИ - Сидорова
10:38 26.03.2014



Путин призвал МВД использовать в Крыму опыт работы на Олимпиаде
14:13 21.03.2014



Два "олимпийских" спецавтопарка останутся в Сочи как наследие Игр
11:50 26.03.2014

Требования к кластерам

- Задача кластеризации новостей по содержанию.
- Постановка 3: в один кластер должны попадать тексты об одной и той же новости

11:41, 08 ФЕВРАЛЯ 2014

Открытие Олимпиады в Сочи
посмотрели несколько миллиардов
человек


Олимпиада в Сочи открыта

**Церемония открытия Олимпиады в
Сочи. Онлайн-репортаж**

Требования к кластерам

- Чтобы проверить, выполняются ли требования, нужно делать разметку данных
- Для новостей: показывать ассессору пары документов и спрашивать, относятся ли они к одному кластеру

Кластеризация как основная задача





Кластеризация как вспомогательная задача

Цель: улучшение распознавания

5 5 5 5 5

«Жёсткая» и «мягкая» кластеризации

Кластеризация для выделения «тем»




«Жёсткая» и «мягкая» кластеризации

Кластеризация для выделения «тем»



0.2



0.3



0.5

Типы задач кластеризации

- Форма кластеров, которые нужно выделять
- Плоская или древовидная структура
- Размер кластеров
- Конечная задача или вспомогательная
- Жесткая или мягкая кластеризация

K-Means

K-Means


- Дано: выборка $x_1, \dots, x_\ell$
- Параметр: число кластеров K
- Начало: случайно выбрать K центров кластеров $c_1, \dots, c_K$
- Повторять по очереди до сходимости:
 - Шаг А: отнести каждый объект к ближайшему центру
$$y_i = \arg \min_{j=1, \dots, K} \rho(x_i, c_j)$$
 - Шаг Б: переместить центр каждого кластера в центр тяжести

$$c_j = \frac{\sum_{i=1}^{\ell} x_i [y_i = j]}{\sum_{i=1}^{\ell} [y_i = j]}$$


K-Means




(a)




(b)




(c)



(d)









(e)



(f)

K-Means




Выбор числа кластеров

- Качество кластеризации: внутрикластерное расстояние



$$J(C) = \sum_{i=1}^{\ell} \rho(x_i, c_{y_i})$$

- Зависит от K
- Нужно подобрать такое K , после которого качество меняется не слишком сильно

Выбор числа кластеров



Выбор числа кластеров




Особенности K-Means

- Может работать с большими объёмами данных
- Подходит для кластеров с простой геометрией
- Требуется выбора числа кластеров

Mean Shift

Парзеновское ядро

- Обозначение: $K(z)$
- Чем ближе к нулю z , тем больше $K(z)$
- Примеры:
 - $K(z) = \exp\left(\frac{z}{h}\right)$
 - $K(z) = [z \leq h]$



Mean Shift

Пусть дан объект x

1. Вычисляем окрестность $N(x)$ — объекты, где $K(\rho(x, x_i)) > \varepsilon$
2. Находим градиент плотности:

$$m(x) = \frac{\sum_{x_i \in N(x)} x_i K(\rho(x, x_i))}{\sum_{x_i \in N(x)} K(\rho(x, x_i))} - x$$

3. Делаем шаг:


$$x \leftarrow x + m(x)$$

4. Повторяем до сходимости


Mean Shift

- Алгоритм запускается для каждого объекта
- Те объекты, для которых алгоритм сходится в общую точку, относятся к одному кластеру


Mean-Shift




Mean-Shift




Mean-Shift



Mean-Shift




Mean Shift



Density-based clustering

Основные, граничные и шумовые точки




Параметры DBSCAN

- Размер окрестности (eps)
- Минимальное число объектов в окрестности — для определения основных точек

DBSCAN



(a) Clusters found by DBSCAN.




x - Noise Point + - Border Point o - Core Point





(b) Core, border, and noise points.

1. Выбрать точку без метки
2. Если в окрестности меньше N точек, то пометить как шумовую
3. Создать новый кластер, поместить в него текущую точку
4. Для всех точек из окрестности S : (а) если точка шумовая, то отнести к данному кластеру, но не использовать для расширения; (б) если точка основная, то отнести к данному кластеру, а её окрестность добавить к S
5. Перейти к шагу 1





DBSCAN: результаты работы



Пример



Пример



Особенности DBSCAN


- Находит кластеры произвольной формы
- Может работать с большими объёмами данных
- Нужно подбирать размер окрестности (ϵ) и минимальное число объектов в окрестности

Графовые методы


Кластеризация по компонентам связности

- Граф: вершины соответствуют объектам
- Соединяем ребром объекты, расстояние между которыми меньше R
- Выделяем компоненты связности

Выделение связных компонент




Выделение связных компонент



Кластеризация по компонентам связности

- Быстрая и простая
- Параметр — минимальное расстояние R
- Проблема: непонятно, как выбрать R , если нужно получить K кластеров

Минимальное остовное дерево



Минимальное остовное дерево

- Строим взвешенный граф, где веса ребер – расстояния между объектами
- Строим минимальное остовное дерево для этого графа
- Дерево имеет $\ell - 1$ ребро
- Удаляем $K - 1$ ребро с максимальным весом
- Получаем K компонент связности, которые интерпретируем как кластеры

Обучение без учителя и
текстовые данные

Похожие слова

- «Идти» и «шагать» — синонимы
- Для компьютера это разные строки
- Как понять, что они похожи?

Похожие слова

- «Идти» и «шагать» — синонимы
- Для компьютера это разные строки
- Как понять, что они похожи?
- На основе данных!
- Слова со схожим смыслом часто идут в паре с одними и теми же словами
- У них похожие контексты

Дистрибутивная семантика

- У похожих по смыслу слов похожие *контексты*
- Контекст — окрестность слова

...an efficient method for learning high quality distributed vector ...

Diagram illustrating the concept of context in distributed semantics. The sentence "...an efficient method for learning high quality distributed vector ..." is shown. The word "learning" is highlighted in yellow and labeled "focus word" with a blue arrow pointing to it. The words "an efficient method for" are grouped by a green bracket and labeled "context". The words "high quality distributed vector" are also grouped by a green bracket and labeled "context".

Векторные представления слов

Хотим представить каждое слово в виде вещественного вектора:

$$w \rightarrow \vec{w} \in \mathbb{R}^d$$


Требования к представлениям (embeddings):

- Размерность d должна быть не очень большой
- Похожие слова должны иметь близкие векторы
- Арифметические операции над векторами должны иметь смысл

word2vec

Задача:

- Для каждого слова w построить вектор $\vec{w}$
- Если два слова w_1 и w_2 идут рядом, то скалярное произведение $\langle \vec{w}_1, \vec{w}_2 \rangle$ должно быть большим



word2vec

Если два слова w_1 и w_2 идут рядом, то скалярное произведение $\langle \vec{w}_1, \vec{w}_2 \rangle$ должно быть большим:

$$p(w_i | w_j) = \frac{\exp(\langle \vec{w}_i, \vec{w}_j \rangle)}{\sum_{w \in W} \exp(\langle \vec{w}, \vec{w}_j \rangle)}$$

$$\sum_{i=1}^{\ell} \sum_{j=1}^{n_i} \sum_{\substack{k=-K \\ k \neq 0}}^K \log p(\vec{w}_{j+k} | \vec{w}_j) \rightarrow \max_{\{\vec{w}\}_{w \in W}}$$



word2vec

Векторы можно прибавлять и вычитать:

- $\overrightarrow{\text{король}} - \overrightarrow{\text{мужчина}} + \overrightarrow{\text{женщина}} \approx \overrightarrow{\text{королева}}$
- $\overrightarrow{\text{медведь}} - \overrightarrow{\text{Россия}} + \overrightarrow{\text{Австралия}} \approx \overrightarrow{\text{кенгуру}}$

Можно переводить слова:

- $\overrightarrow{\text{математика}} + (\overrightarrow{\text{word}} - \overrightarrow{\text{слово}}) \approx \overrightarrow{\text{math}}$
- $\overrightarrow{\text{король}} + (\overrightarrow{\text{word}} - \overrightarrow{\text{слово}}) \approx \overrightarrow{\text{king}}$
- $\overrightarrow{\text{корова}} + (\overrightarrow{\text{word}} - \overrightarrow{\text{слово}}) \approx \overrightarrow{\text{cow}}$



Примеры представлений

- food2vec
 - Документ — названия ингредиентов из рецепта
 - Слово — один ингредиент

food2vec

Tools for cooking with machine intelligence

Food similarity tool

Type in an ingredient to see which foods are similar:

Type in a food (e.g. Apple, Peanut, Bread)

Almonds



LOOK UP SIMILAR FOODS!

Whole almonds	0.708
Slivered almonds	0.695
Chopped almonds	0.657
Blanched almonds	0.651
Chocolate	0.616
Prunes	0.602
Raisins	0.597
Toasted almonds	0.589
Dried dates	0.586

<https://altosaar.github.io/food2vec/>

Примеры представлений

- Общее семантическое пространство в Яндексе
 - В векторы переводятся страницы сайтов, изображения, видео, ...

Тематическое моделирование

- Рассматриваем каждый документ как мешок слов
- Всего K тем
- Тема — распределение на словах
- Документ — распределение на темах

Тематическое моделирование

Topics

gene	0.04
dna	0.02
genetic	0.01
...	

life	0.02
evolve	0.01
organism	0.01
...	

brain	0.04
neuron	0.02
nerve	0.01
...	

data	0.02
number	0.02
computer	0.01
...	

Documents

Seeking Life's Bare (Genetic) Necessities

COLD SPRING HARBOR, NEW YORK—How many **genes** does an **organism** need to **survive**? Last week at the genome meeting here,* two genome researchers with radically different approaches presented complementary views of the basic genes needed for **life**. One research team, using **computer** analyses to compare known **genomes**, concluded that today's **organisms** can be sustained with just 250 genes, and that the earliest life forms required a mere 128 **genes**. The other researcher mapped genes in a simple parasite and estimated that for this organism, 800 genes are plenty to do the job—but that anything short of 100 wouldn't be enough.

Although the numbers don't match precisely, those **predictions**

"are not all that far apart," especially in comparison to the 75,000 **genes** in the human genome, notes Siv Andersson at Uppsala University in Sweden, who arrived at the 800 number. But coming up with a consensus answer may be more than just a **genetic** numbers game, particularly as more and more **genomes** are completely mapped and sequenced. "It may be a way of organizing any newly **sequenced genome**," explains Arcady Mushegian, a **computational** molecular biologist at the National Center for Biotechnology Information (NCBI) in Bethesda, Maryland. Comparing an




* Genome Mapping and Sequencing, Cold Spring Harbor, New York, May 8 to 12.

Stripping down. **Computer analysis** yields an estimate of the minimum modern and ancient genomes.

SCIENCE • VOL. 272 • 24 MAY 1996

Topic proportions and assignments



Модель PLSA

- Probabilistic Latent Semantic Analysis

$$p(w|d) = \sum_{t \in T} p(w|t)p(t|d) = \sum_{t \in T} \varphi_{wt} \theta_{td}$$

- T — множество тем
- $p(w|t) = \varphi_{wt}$ — распределение слов в теме t
- $p(t|d) = \theta_{td}$ — распределение тем в документе d

Модель PLSA

- Probabilistic Latent Semantic Analysis


$$\sum_{d \in D} \sum_{w \in W} n_{dw} \log p(w|d) \rightarrow \max_{\varphi_{wt}, \theta_{td}}$$

Ограничения: $\varphi_{wt} \geq 0, \theta_{td} \geq 0, \sum_{w \in W} \varphi_{wt} = 1, \sum_{t \in T} \theta_{td} = 1$

- D — множество документов
- W — множество слов

Примеры

- Данные: сообщения с форума вегетарианцев



11 Nutrition

pre_soak
contain_40_100
carbohydrate_rich
2200_calorie
cronometer
kaiser_permanente_one
9_essential_amino_acid
ripeness
large_health_insurance
amino_acid_profile
powder1/2_tsp
nuts_nut_butter
chronometer
300_g
mineral_deficiency
1400_calorie
1600_calorie
sliced1
myfitnesspal
bmr
tigress
250_g
dry_oregano
120_calorie
200_g
managable
howdy
aid_digestion
high_carb_low_fat
page_7

12 Ingredients

over_jasmine_rice
fennel_seed
bpa
soaking_water
chop_celery
fallout
dragon_fruit
arroz
red_lentil
pourable
bean_pulse
garlic_ginger
roasted_peanut
toast_sesame_oil
23rd
finely_ground
grape_nuts
exporter
pinto
tortilla_wraps
rehydrat
kombu
finely_dice
chapati
chamomile_tea
onions
navy_bean
pyrex
chamomile
fresh_rosemary

26 Supplements

1000_mcg
dill_weed
blanch_almond
dha_epa_supplement
unsweetened_variety
ala
numbness
dha_epa
epa_dha
epa
dr_weil
stir_fried_veggie
free_sample_toy
enfamil_family_beginnings
algae_dha
conflicting_information
deva
panko
methyl
atmospheric
purchasing_decision
dha
fresher
mouse_trap
soy_milk_maker
dha_supplement
msm
£_15
chilli_sauce
wrath

34 Electronics

inny
s620
tmj
m500
mobile_sidekick_3
p3600
innie
510
e90_s
iphone_8_gb_s
mpx_300
station_2
e70
140nokia
n75
ipod_nano_4_gb
iphone_8gb
sidekick_3
xbox_360
motorola
t_mobile
razr
ericsson_w900i
itouch
us\$
v3x
=_=_=
d500
16gb
belly_button

22 Shoes

meo
conch
sizing
snowshoe
abalone
cowboy_boot
mandolin
old_bay
hike_boot
gladiator
empty_shell
reform_movement
sand_dollar
steel_toe
candle_holder
insole
versary
zappos.com
irc
snow_boot
jojoba
yesss
canvas_shoe
hiking_boot
skating
southern_accent
moo_shoes
sautéed_mushroom
rei
herb_garden

21 Dieticians

an_expert_button_locate
dietitians_new_zealand_website
freelance_dietitians_website
hand_portion
local_registered_dietitian
upper_right
local_register_dietitian_through
branding
marvel
dr_neal_barnard
by_dr_neal
nepal
personalized
nascar
oxalic_acid
disputable
vegecat
faux_fur
consignment_shop
tabling
\$_24
registered_dietitian
downloadable
chrome
tv_series
reverse_diabete
faux_fur_trim
herbivore_magazine
standardize
cress

19 Eggs

dr_greger
shill
incubate
thunder_chicken
global_population
pet_ownership
menstrual_fluid
terri
eyeliner
futon
harm_reduction
envoyé_de_mon_iphone
backyard_chicken
societal_pressure
rescue_hen
opaque
emission
t_colin_campbell
dark_spot
boy_chick
vegan?do
dha_epa
pringles
an_unfertilized_egg
local_coffee_shop
en_utilisant_tapatalk
menstruation
unfertiliz_egg
juice_feast
flashlight

Примеры

- Данные: новостные заголовки

Topic: 0 Word: 0.008*"octob" + 0.006*"search" + 0.006*"miss" + 0.006*"inquest" + 0.005*"stori" + 0.005*"jam" + 0.004*"john" + 0.004*"harvest" + 0.004*"australia" + 0.004*"world"

Topic: 1 Word: 0.006*"action" + 0.006*"violenc" + 0.006*"thursday" + 0.005*"domest" + 0.005*"cancer" + 0.005*"legal" + 0.005*"union" + 0.005*"breakfast" + 0.005*"school" + 0.004*"student"

Topic: 2 Word: 0.023*"rural" + 0.018*"govern" + 0.013*"news" + 0.012*"podcast" + 0.008*"grandstand" + 0.008*"health" + 0.007*"budget" + 0.007*"busi" + 0.007*"nation" + 0.007*"fund"

Topic: 3 Word: 0.030*"countri" + 0.028*"hour" + 0.009*"sport" + 0.008*"septemb" + 0.008*"wednesday" + 0.007*"commiss" + 0.006*"royal" + 0.006*"updat" + 0.006*"station" + 0.005*"bendigo"

Topic: 4 Word: 0.014*"south" + 0.009*"weather" + 0.009*"north" + 0.008*"west" + 0.008*"coast" + 0.008*"australia" + 0.006*"east" + 0.006*"queensland" + 0.006*"storm" + 0.005*"season"

Topic: 5 Word: 0.008*"monday" + 0.008*"august" + 0.006*"babi" + 0.005*"shorten" + 0.005*"hobart" + 0.004*"victorian" + 0.004*"donald" + 0.004*"safe" + 0.004*"scott" + 0.004*"donat"

Topic: 6 Word: 0.022*"interview" + 0.013*"market" + 0.009*"share" + 0.008*"cattl" + 0.008*"trump" + 0.008*"turnbul" + 0.007*"novemb" + 0.007*"michael" + 0.006*"australian" + 0.006*"export"

Topic: 7 Word: 0.019*"crash" + 0.014*"kill" + 0.009*"fatal" + 0.009*"dead" + 0.007*"die" + 0.007*"truck" + 0.007*"polic" + 0.006*"attack" + 0.006*"injur" + 0.006*"bomb"

Topic: 8 Word: 0.008*"drum" + 0.007*"abbott" + 0.007*"farm" + 0.006*"dairi" + 0.006*"asylum" + 0.006*"tuesday" + 0.006*"water" + 0.006*"labor" + 0.006*"say" + 0.005*"plan"

Topic: 9 Word: 0.017*"charg" + 0.014*"murder" + 0.011*"court" + 0.011*"polic" + 0.009*"woman" + 0.008*"assault" + 0.008*"jail" + 0.008*"alleg" + 0.007*"accus" + 0.007*"guilti"

Резюме

- Кластеризация — задача без строгой постановки и без строгих критериев качества
- Много разновидностей в подходах
- Методы: K-Means, DBSCAN, графовые и т.д.
- Обучение без учителя — гораздо более широкая область


Отбор признаков

На прошлых лекциях

- Методы машинного обучения: линейные модели, решающие деревья, случайные леса, ...
- Дано: матрица «объекты-признаки» X и ответы y
- Найти: модель $a(x)$

Биоинформатика

- Задачи анализа генома человека
- Признаки: характеристики генов (более 20.000)
- Маленькие выборки (расшифровка генома — сложная и дорогостоящая процедура)
- Признаков существенно больше, чем объектов!



Категориальные признаки

- Пример: предсказать, понравится ли пользователю фильм
- Объект: пара «пользователь-фильм»
- Признаки: ID пользователя, ID фильма, ID жанра, ID режиссёра, ID главных актёров, ID композитора, ...
- Как много фильмов снято за всю историю?

Категориальные признаки

- Пример: предсказать, понравится ли пользователю фильм
- Объект: пара «пользователь-фильм»
- Признаки: ID пользователя, ID фильма, ID жанра, ID режиссёра, ID главных актёров, ID композитора, ...
- IMDB: >330 тысяч
- После бинарного кодирования получим миллионы признаков

Анализ текстов

- Пример: предсказание популярности фильма по тексту его сценария
- Признаки: количество вхождений каждого слова из словаря
- Сколько слов в словаре?

Анализ текстов

- Пример: предсказание популярности фильма по тексту его сценария
- Признаки: количество вхождений каждого слова из словаря
- Сотни тысяч признаков
- Если учитывать n -граммы, то десятки миллионов признаков

Анализ данных ЭЭГ

- Энцефалограф: 64 датчика, частота сигнала 256 Гц
- Объект: результаты измерений для одного пациента
- За 5 секунд измерений: $64 * 256 * 5 = 81\,920$ признаков



UCI Machine Learning Repository



Machine Learning Repository
Center for Machine Learning and Intelligent Systems

About Citation Policy Donate a Data Set Contact

Search

Repository Web

Google

View ALL Data Sets

Browse Through:

Default Task

Classification (255)
Regression (60)
Clustering (52)
Other (51)

Attribute Type

Categorical (37)
Numerical (204)
Mixed (56)

Data Type

Multivariate (272)
Univariate (16)
Sequential (35)
Time-Series (61)
Text (30)
Domain-Theory (21)
Other (21)

Area

Life Sciences (82)
Physical Sciences (43)
CS / Engineering (104)
Social Sciences (23)
Business (19)
Game (9)
Other (66)

Attributes

Less than 10 (84)
10 to 100 (158)
Greater than 100 (55)

Instances

Less than 100 (16)

349 Data Sets

Table View

List View

Name	Data Types	Default Task	Attribute Types	# Instances	# Attributes	Year
 URL Reputation	Multivariate, Time-Series	Classification	Integer, Real	2396130	3231961	2009
 Gas sensor arrays in open sampling settings	Multivariate, Time-Series	Classification	Real	18000	1950000	2013
 YouTube Multiview Video Games Dataset	Multivariate, Text	Classification, Clustering	Integer, Real	120000	1000000	2013
 Gas sensor array exposed to turbulent gas mixtures	Multivariate, Time-Series	Classification, Regression	Real	180	150000	2014
 ElectricityLoadDiagrams20112014	Time-Series	Regression, Clustering	Real	370	140256	2015
 PEMS-SF	Multivariate, Time-Series	Classification	Real	440	138672	2011
 Gas sensor array under flow modulation	Multivariate, Time-Series	Classification, Regression	Real	58	120432	2014
 Bag of Words	Text	Clustering	Integer	8000000	100000	2008

Задача понижения размерности

- Дано: матрица «объекты-признаки» $\mathbf{X}$ размера $\ell \times \mathbf{D}$
- Найти: новую матрицу «объекты-признаки» $\mathbf{Z}$ размера $\ell \times \mathbf{d}$
- $d < D$

Но зачем?

- Проклятие размерности
- Шумовые признаки
- Переобучение
- Интерпретируемость модели
- Скорость работы модели
- Визуализация данных

Проклятие размерности

- Задача: классификация пончиков на вкусные и невкусные
- 100 объектов
- Цвет: 10 вариантов
- Цвет + размер: $10 * 4 = 40$ вариантов
- Цвет + размер + форма: $10 * 4 * 4 = 160$ вариантов




Проклятие размерности

- Задача: классификация пончиков на вкусные и невкусные
- 100 объектов
- Цвет + размер + форма + начинка: $10 * 4 * 4 * 20 = 3200$ вариантов
- Цвет + размер + форма + начинка + топпинг: $10 * 4 * 4 * 20 * 10 = 32000$ вариантов
- Чем больше признаков, тем меньше пончики похожи




Проклятие размерности



Плохие признаки


Информативный
признак



Плохие признаки


Коррелирующие
признаки

f_2 — избыточный
признак



Плохие признаки


f3 — шумовой
признак



Шумовые признаки

- Признаки, которые никак не связаны с целевой переменной
- Но по обучающей выборке это не всегда можно понять

Шумовые признаки



Шумовые признаки

- Генерируем случайные признаки
- Если их много, то некоторые будут хорошо коррелировать с ответами

y	x_1	x_2	x_3	x_4
-1	1.11	-0.5	0.42	0.33
-1	1.22	-0.46	-1.98	-0.55
1	-1.56	0.04	0.39	-1.67
1	-0.48	1.32	0.88	-0.27

Ускорение моделей

- Чем больше признаков, тем дольше обучаются модели
- Чем дольше обучаются модели, тем меньше экспериментов удаётся провести

Ускорение моделей


- Чем больше признаков, тем сложнее модели
- Чем сложнее модели, тем дольше они вычисляют прогнозы
- Могут быть жёсткие ограничения на скорость
- Пример: рекомендательные системы

Визуализация

-99.99	-99.99	315.7	317.45	317.5	317.26	315.86	314.93	313.2	312.44	313.33	314.67	-99.99
315.62	316.38	316.71	317.72	318.29	318.16	316.54	314.8	313.84	313.26	314.8	315.58	315.98
316.43	316.97	317.58	319.02	320.03	319.59	318.18	315.91	314.16	313.84	315	316.19	316.91
316.93	317.7	318.54	319.48	320.58	319.77	318.57	316.79	314.8	315.38	316.1	317.01	317.64
317.94	318.56	319.68	320.63	321.01	320.55	319.58	317.4	316.25	315.42	316.69	317.7	318.45
318.74	319.08	319.86	321.39	322.24	321.47	319.74	317.77	316.21	315.99	317.12	318.31	318.99
319.57	-99.99	-99.99	-99.99	322.24	321.89	320.44	318.7	316.7	316.79	317.79	318.71	-99.99
319.44	320.44	320.89	322.13	322.16	321.87	321.39	318.8	317.81	317.3	318.87	319.42	320.04
320.62	321.59	322.39	323.87	324.01	323.75	322.39	320.37	318.64	318.1	319.79	321.08	321.38
322.06	322.5	323.04	324.42	325	324.09	322.55	320.92	319.31	319.31	320.72	321.96	322.16
322.57	323.15	323.89	325.02	325.57	325.36	324.14	322.03	320.41	320.25	321.31	322.84	323.05
324	324.42	325.64	326.66	327.34	326.76	325.88	323.67	322.38	321.78	322.85	324.12	324.63
325.03	325.99	326.87	328.14	328.07	327.66	326.35	324.69	323.1	323.16	323.98	325.13	325.68
326.17	326.68	327.18	327.78	328.92	328.57	327.34	325.46	323.36	323.57	324.8	326.01	326.32
326.77	327.63	327.75	329.72	330.07	329.09	328.05	326.32	324.93	325.06	326.5	327.55	327.45
328.55	329.56	330.3	331.5	332.48	332.07	330.87	329.31	327.51	327.18	328.16	328.64	329.68
329.35	330.71	331.48	332.65	333.09	332.25	331.18	329.4	327.43	327.37	328.46	329.57	330.25
330.4	331.41	332.04	333.31	333.96	333.6	331.91	330.06	328.56	328.34	329.49	330.76	331.15
331.75	332.56	333.5	334.58	334.87	334.34	333.05	330.94	329.3	328.94	330.31	331.68	332.15
332.93	333.42	334.7	336.07	336.74	336.27	334.93	332.75	331.59	331.16	332.4	333.85	333.9
334.97	335.39	336.64	337.76	338.01	337.89	336.54	334.68	332.76	332.55	333.92	334.95	335.51
336.23	336.76	337.96	338.89	339.47	339.29	337.73	336.09	333.91	333.86	335.29	336.73	336.85
338.01	338.36	340.08	340.77	341.46	341.17	339.56	337.6	335.88	336.02	337.1	338.21	338.69
339.23	340.47	341.38	342.51	342.91	342.25	340.49	338.43	336.69	336.86	338.36	339.61	339.93
340.75	341.61	342.7	343.57	344.13	343.35	342.06	339.81	337.98	337.86	339.26	340.49	341.13
341.37	342.52	343.1	344.94	345.75	345.32	343.99	342.39	339.86	339.99	341.15	342.99	342.78
343.7	344.5	345.28	347.08	347.43	346.79	345.4	343.28	341.07	341.35	342.98	344.22	344.42
344.97	346	347.43	348.35	348.93	348.25	346.56	344.68	343.09	342.8	344.24	345.55	345.9
346.3	346.96	347.86	349.55	350.21	349.54	347.94	345.9	344.85	344.17	345.66	346.9	347.15
348.02	348.47	349.42	350.99	351.84	351.25	349.52	348.1	346.45	346.36	347.81	348.96	348.93
350.43	351.73	352.22	353.59	354.22	353.79	352.38	350.43	348.72	348.88	350.07	351.34	351.48
352.76	353.07	353.68	355.42	355.67	355.13	353.9	351.67	349.8	349.99	351.29	352.52	352.91
353.66	354.7	355.39	356.2	357.16	356.23	354.82	352.91	350.96	351.18	352.83	354.21	354.19
354.72	355.75	357.16	358.6	359.33	358.24	356.17	354.02	352.15	352.21	353.75	354.99	355.59
355.98	356.72	357.81	359.15	359.66	359.25	357.02	355	353.01	353.31	354.16	355.4	356.37
356.7	357.16	358.38	359.46	360.28	359.6	357.57	355.52	353.69	353.99	355.34	356.8	357.04
358.37	358.91	359.97	361.26	361.68	360.95	359.55	357.48	355.84	355.99	357.58	359.04	358.89
359.97	361	361.64	363.45	363.79	363.26	361.9	359.46	358.05	357.76	359.56	360.7	360.88
362.05	363.25	364.02	364.72	365.41	364.97	363.65	361.48	359.45	359.6	360.76	362.33	362.64
363.18	364	364.56	366.35	366.79	365.62	364.47	362.51	360.19	360.77	362.43	364.28	363.76
365.33	366.15	367.31	368.61	369.3	368.87	367.64	365.77	363.9	364.23	365.46	366.97	366.63
368.15	368.87	369.59	371.14	371	370.35	369.27	366.93	364.63	365.13	366.67	368.01	368.31
369.14	369.46	370.52	371.66	371.82	371.7	370.12	368.12	366.62	366.73	368.29	369.53	369.48
370.28	371.5	372.12	372.87	374.02	373.3	371.62	369.55	367.96	368.09	369.68	371.24	371.02
372.43	373.09	373.52	374.86	375.55	375.41	374.02	371.49	370.7	370.25	372.08	373.78	373.1
374.68	375.63	376.11	377.65	378.35	378.13	376.62	374.5	372.99	373.01	374.35	375.7	375.64
376.79	377.37	378.41	380.52	380.63	379.57	377.79	375.86	374.07	374.24	375.86	377.47	377.38
378.37	379.69	380.41	382.1	382.28	382.13	380.66	378.71	376.42	376.88	378.32	380.04	379.67
381.38	382.03	382.64	384.62	384.95	384.06	382.29	380.47	378.67	379.06	380.14	381.74	381.84
382.45	383.68	384.23	386.26	386.39	385.87	384.39	381.78	380.73	380.81	382.33	383.69	383.55
385.07	385.72	385.85	386.71	388.45	387.64	386.1	383.95	382.91	382.73	383.96	385.02	385.34

Визуализация

t-SNE 2D Embedding of Products Data



Методы понижения размерности

- Отбор признаков (feature selection)
 - Выбрать d самых важных признаков
- Извлечение признаков (feature extraction)
 - Найти d новых признаков, выражающихся через исходные

Методы понижения размерности

- Фильтрация (filter methods)
 - Понижение размерности без учёта модели
- Методы-обёртки (wrapper methods)
 - Выбор признаков, дающих лучшее качество для модели
- Понижение с помощью моделей (embedded methods)
 - Использование свойств моделей для оценивания важности признаков

Одномерные методы

Одномерные методы

- Оценивают важность каждого признака по отдельности
- Относятся к **методам фильтрации**
- Относятся к **методам отбора признаков**

Обозначения

- x_{ij} — значение j -го признака на i -м объекте
- $\bar{x}_j$ — среднее значение j -го признака
- y_i — значение целевой переменной на i -м объекте
- $\bar{y}$ — среднее значение целевой переменной

Дисперсия признаков

$$R_j = \frac{1}{\ell} \sum_{i=1}^{\ell} (x_{ij} - \bar{x}_j)^2$$


- Чем больше R_j , тем информативнее признак
- Никак не учитываются ответы
- Подходит для фильтрации константных и близких к ним признаков

Корреляция


$$R_j = \frac{\sum_{i=1}^{\ell} (x_{ij} - \bar{x}_j)(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{\ell} (x_{ij} - \bar{x}_j)^2 \sum_{i=1}^{\ell} (y_i - \bar{y})^2}}$$

- Чем больше $|R_j|$, тем информативнее признак
- Учитывает только линейную связь

Корреляция для регрессии




Корреляция
0.927




Корреляция
0.207

Корреляция для классификации



Корреляция
0.741




Корреляция
0.0

T-score


$$R_j = \frac{|\mu_1 - \mu_2|}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$

- Для задач бинарной классификации
- Чем больше R_j , тем информативнее признак
- μ_1, μ_2 — средние значения признаков в первом и втором классах
- σ_1^2, σ_2^2 — дисперсии
- n_1, n_2 — число объектов в первом и втором классах

T-score



T-score
4.95



T-score
2.28

F-score

$$R_j = \frac{\sum_{k=1}^K \frac{n_j}{K-1} (\mu_j - \mu)^2}{\frac{1}{\ell - K} \sum_{k=1}^K (n_j - 1) \sigma_j^2}$$


- Для задач многоклассовой классификации
- Чем больше R_j , тем информативнее признак
- $\mu_1, \dots, \mu_K$ — средние значения признаков в классах
- μ — среднее значение признака по всей выборке
- $\sigma_1^2, \dots, \sigma_K^2$ — дисперсии
- $n_1, \dots, n_K$ — число объектов в первом и втором классах

Пример: Titanic


	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26	0	0	STON/O2. 3101282	7.9250	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35	0	0	373450	8.0500	NaN	S

Пример: Titanic


- Вычислим T-score для всех признаков
- Действительно, пол сильнее всего коррелирует с выживаемостью пассажиров



Проблемы





Проблемы



Проблемы

- Одномерные критерии не работают, если целевая переменная зависит от совокупностей признаков



Отбор с помощью моделей

Отбор с помощью моделей

- Оценивают важность признаков, используя модели машинного обучения
- Относятся к **методам отбора признаков**

Линейные модели

$$a(x) = \sum_{j=1}^d w_j x_j$$


- Если признаки масштабированы, то веса можно использовать как показатели информативности
- Для повышения числа нулевых весов — L_1 -регуляризация

L_1 -регуляризация

$$Q(a, X) + \lambda \sum_{j=1}^d |w_j| \rightarrow \min_w$$

- Чем выше λ , тем больше весов зануляется
- Позволяет построить модель, использующую только самые важные признаки

L_1 -регуляризация



Решающие деревья

- Поиск лучшего разбиения:

$$Q(X_m, j, t) = H(X_m) - \frac{|X_l|}{|X_m|} H(X_l) - \frac{|X_r|}{|X_m|} H(X_r) \rightarrow \max_{j,t}$$

- $H(X)$ — критерий информативности (MSE, энтропийный)

Решающие деревья

- Чем сильнее уменьшили $H(X)$, тем лучше признак

- Уменьшение критерия:

$$H(X_m) - \frac{|X_l|}{|X_m|} H(X_l) - \frac{|X_r|}{|X_m|} H(X_r)$$


- Важность признака R_j : просуммируем уменьшения по всем вершинам, где разбиение делалось по признаку j

Случайный лес


- Сумма важностей R_j по всем деревьям
- Чем больше, тем важнее признак
- Учитывается важность признаков в совокупности

Случайные леса и отбор признаков


- Классификация вин на белые и красные




Пример: Titanic



Одномерный отбор




Логистическая регрессия



Случайный лес

Пример: Titanic

- Модели выделяют признак Age как важный
- Ответы зависят от возраста только в совокупности с полом



Методы-обёртки

Перебор

- Пробуем выкинуть каждый признак, смотрим, как это влияет на качество, выкидываем лучший вариант
- Повторяем, пока качество растёт
- Можно наоборот: добавлять по одному
- Ещё варианты: случайный поиск, генетические алгоритмы и т.д.